

ERICK MEJIA -2006104 - JOSÉ ORDOÑEZ - 20000280 - RODRIGO ÁVILA - 21000128

1

INTRODUCCIÓN

- Las enfermedades cardiovasculares son una de las principales causas de muerte a nivel mundial, según la OMS.
- Diagnosticar de forma temprana es clave para salvar vidas.
- La inteligencia artificial permite automatizar y mejorar la precisión en la detección de estas condiciones a partir de datos médicos.
- Este proyecto busca desarrollar un modelo de red neuronal capaz de predecir si un paciente presenta riesgo cardíaco, con base en variables clínicas comunes.

2

DESCRIPCIÓN DEL DATASET

- El dataset "Heart Disease" contiene información clínica de pacientes de cuatro hospitales.
- Se compone de 76 atributos totales, pero se utilizaron los 14 más relevantes como: edad, sexo, presión arterial, colesterol, frecuencia cardíaca, tipo de dolor torácico, entre otros.
- La variable objetivo indica la presencia (1) o ausencia (0) de enfermedad cardíaca.
- El dataset está razonablemente balanceado, por lo que no fue necesario aplicar técnicas de oversampling.

3

METODOLOGÍA



- Se desarrolló un modelo de clasificación binaria con redes neuronales y activación Sigmoid.
- Se implementó normalización Z-score manual con pandas.
- Se evaluaron cuatro arquitecturas:
 1. Modelo principal (32-32)
 2. Modelo simple (menos neuronas) (16)
 3. Red Estricta (64-32)
 4. Transfer Learning (MobileNetV2 con imágenes simuladas)
- Se utilizó un umbral de 0.6 para la clasificación final.
- Se emplearon métricas como Accuracy, Precision y Recall para comparar desempeño.

4

RESULTADOS

- El modelo principal logró una accuracy del 91%, con buena precisión y recall.
- El modelo estricto superó ligeramente en desempeño, pero a costa de mayor complejidad.
- Transfer learning no funcionó bien debido a que el dataset no contiene imágenes reales.
- Se graficaron las métricas clave y la matriz de confusión para el análisis comparativo.

ACCURACY:



5

CONCLUSIONES

- La arquitectura del modelo principal fue suficiente para alcanzar un excelente desempeño sin necesidad de oversampling.
- El preprocesamiento, en especial la normalización manual, tuvo un impacto notable en la calidad del modelo.
- Modelos más profundos ofrecieron mejoras marginales, mientras que transfer learning no fue adecuado para datos tabulares.
- La inteligencia artificial tiene potencial real en el apoyo a diagnósticos médicos si se aplica con una buena comprensión del contexto de los datos.

6

MEJORAS A FUTURO

- Implementar validación cruzada k-fold para obtener una evaluación más robusta.
- Probar técnicas de selección de características para reducir dimensionalidad.
- Investigar técnicas de interpretabilidad como SHAP o LIME para explicar las predicciones del modelo.
- Aplicar el modelo a conjuntos de datos clínicos más amplios o en tiempo real.